

Aprendizaje por contexto (In-context learning)

Transformers, uso de agentes, LangChain y RAG

Nicolás Cayturo

Motivación

El in-context learning (también conocido como aprendizaje por contexto), es la capacidad de los modelos de lenguaje para aprender una tarea solo a partir de ejemplos o instrucciones provistas en el prompt, sin necesidad de entrenar o hacer fine-tuning de un modelo solo para esa tarea.

¿Cómo funciona?

El modelo observa ejemplos en el prompt y generaliza el patrón para resolver casos nuevos dentro de la misma interacción.

Reseña: “Me encantó la película.” → POSITIVA

Reseña: “No me gustó el final.” → NEGATIVA

Reseña: “Fue interesante pero un poco lenta.” → ...

Prompting

Un prompt convierte una necesidad “humana” en una tarea comprensible para el modelo.

Anatomía recomendada de un prompt

[ROL O SISTEMA]

Eres un experto en IA y profesor del DCC U Chile.

[CONTEXTO]

Los estudiantes conocer Python, pero no han usado LLMs en producción.

[TAREA]

Explica que es few-shot prompting.

[FORMATO]

Responde en 4 viñetas y agrega un ejemplo corto.

Ingeniería de instrucciones

También conocido como *prompt engineering*, es el proceso de diseñar, optimizar y ajustar instrucciones (prompts) para guiar a los modelos de lenguaje y obtener respuestas más precisas, útiles y a medida.

Mejora la calidad, relevancia y especificidad de las respuestas generadas por el modelo.

Prompt poco claro

Resume este texto: ...

Prompt mejorado:

Resume el siguiente texto en máximo 30 palabras, usa un tono formal y redacta como estudiante en ...

Técnicas de instrucciones

Para obtener las mejores respuestas de un modelo de lenguaje, existen varias formas de construir y presentar las instrucciones. Estas técnicas varían desde las más simples, como *dar solo una instrucción*, hasta estrategias más avanzadas que incluyen *ejemplos, reglas, contexto o pasos de razonamiento*.

Zero-shot

En este enfoque, el modelo recibe únicamente la instrucción sobre la tarea a realizar, sin ningún ejemplo adicional que le muestre cómo debe ser la respuesta o salida del modelo.

El modelo debe interpretar la tarea y generar la respuesta adecuada solo a partir de lo que se le indica, utilizando el conocimiento general adquirido durante su entrenamiento.

Clasifica la siguiente reseña de película como POSITIVA o NEGATIVA: “Me aburrí mucho.”

Técnicas de instrucciones

One y few-shot

En estos enfoques, además de la instrucción, se incluyen uno (one-shot) o más (few-shot) ejemplos de entrada y salida en el prompt.

Esto ayuda al modelo a identificar el patrón que debe seguir y a generar respuestas más alineadas con lo esperado, sobre todo en tareas complejas o específicas.

Animal: “Tiburón” → ACUÁTICO
Animal: “Águila” → AÉREO
Animal: “Elefante” → ...

Instrucciones de sistema, de contexto y rol

Este tipo de instrucciones permiten guiar al modelo de manera más precisa al establecer reglas generales (sistema), información relevante (contexto) o asignar un papel específico (rol). Con ellas controlamos mejor el formato, contenido, y estilo de la respuesta generada por el modelo.

Sistema:

Responde solo con una palabra: Sí o NO.

Contexto:

Estás escribiendo para un blog de tecnología dirigido a principiantes.

Rol:

Actúa como profesor experto y responde de manera profesional a la siguiente pregunta.

Instrucciones de sistema, de contexto y rol

Instrucciones de sistema

Este tipo de instrucción define el comportamiento general que debe seguir el modelo, indicando reglas claras sobre el formato, el estilo, límites de la respuesta e incluso la postura que debe adoptar el modelo al momento de dar las respuestas.

Son útiles para controlar el tipo de salida que necesitamos, asegurando respuestas consistentes y adaptadas a nuestros requisitos.

Eres un profesor universitario experto en Inteligencia Artificial. Explica los conceptos de forma clara y con ejemplos.

Instrucciones de sistema, de contexto y rol

Instrucciones de contexto

Las instrucciones de contexto proporcionan información adicional relevante sobre la situación, el objetivo o el público, ayudando al modelo a generar respuestas más precisas y adecuadas al entorno de la tarea.

Al definir el contexto, se logra que la salida esté alineada con necesidades o condiciones específicas.

Contexto: El estudiante tiene conocimientos básicos de Python, pero nunca ha utilizado redes neuronales. Explica qué es una CNN.

Instrucciones de sistema, de contexto y rol

Instrucciones de rol

Las instrucciones de rol asignan al modelo una identidad o especialidad, indicándole que responda como si fuese una persona, profesional o personaje específico.

Esto afecta en el tono, el nivel de detalle y el tipo de conocimiento en la respuesta, haciendo que sea más relevante según el contexto deseado.

Actúa como un profesor universitario experto en Inteligencia Artificial y con más de 10 años de experiencia.

Cadena de pensamiento

Esta técnica consiste en pedir al modelo que explique su razonamiento paso a paso antes de dar la respuesta final.

De este modo, el modelo desglosa el problema en partes, lo cual lleva a soluciones más precisas, especialmente en tareas complejas o de lógica.

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

Técnicas para tareas complejas

Se ejecutan durante inferencia (cuando el modelo responde a un prompt).

Técnica	Descripción	Ejemplo de uso
Self-reflection	El modelo genera una respuesta, la persona revisa la respuesta, detecta posibles errores y le pide al modelo que corrija su respuesta.	Prompt 1: [le damos un problema complejo] ... Prompt 2: Revisa la respuesta anterior y corrige los siguientes errores: ...
Least-to-Most Prompting	Divide un problema complejo en varios subproblemas ordenados de más simple a más complejo, resolviendo cada uno antes de pasar al siguiente.	Resuelve este problema siguiendo estos pasos: 1. Identifica los datos. 2. Calcula las cantidades intermedias. 3. Obtén la respuesta final.
Prompt Chaining	Conecta varios prompts en secuencia; la salida de un prompt se utiliza como entrada al siguiente hasta completar la tarea.	Prompt 1: Resume el documento. Prompt 2: Extrae las ideas principales. Prompt 3: Genera preguntas tipo examen.

Buenas prácticas

Es importante usar ejemplos relevantes, mantener indicaciones claras y simples, y ser específico sobre el formato de salida esperado.

- **Proporcionar ejemplos** para ayudar al modelo a entender mejor la tarea, el formato y el tipo de respuesta que se espera.
- Proporcionar **instrucciones claras, directas y sin información innecesaria** para que el modelo “comprenda” la tarea fácilmente y genere respuestas más acertadas.
- Indicar claramente cómo quieres que sea la respuesta del modelo, definiendo el formato, la extensión, el estilo o el tipo de contenido esperado.
- Es más efectivo decirle al modelo lo que debe hacer (**instrucción**) que decirle solo lo que no haga (**restricción**). Las instrucciones llevan a respuestas más precisas y útiles, mientras que las restricciones pueden generar ambigüedad o respuestas incompletas.
- Redacta tu propio prompt y pídele a un LLM que lo mejore o adecue para una tarea particular.
- Adáptate a actualizaciones del modelo. Diferencia entre versiones.