

# Agentes

*Transformers, uso de agentes, LangChain y RAG*

Nicolás Cayturo

# Motivación

Los agentes autónomos se han reconocido como un acercamiento prometedor para alcanzar la inteligencia artificial general en donde se espera resolver tareas a través de acciones y planificaciones auto guiadas.

A diferencia de la IA actual, que suele estar especializada en tareas concretas, una IA general podría transferir conocimientos entre diferentes áreas y adaptarse a situaciones nuevas sin necesidad de ser reentrenadas específicamente para cada una.

Antes, los agentes se concebían como funciones altamente restringidas al dominio en donde fueron ajustadas, pero esto es alejado al aprendizaje humano, en donde se aprende desde una variedad de ambientes (experiencia).

# Agentes

## Definición de Agente

Un agente es cualquier entidad capaz de percibir su entorno a través de sensores y actuar sobre ese entorno mediante actuadores.

## La Ecuación Fundamental:

Agente = Arquitectura + Programa

## Diferenciación Clave:

- **Función del Agente:** La descripción matemática abstracta que mapea la historia de percepciones a una acción.
- **Programa del Agente:** La implementación concreta que se ejecuta en el hardware físico.



### Humano:

Sensores (Ojos, Oídos) →  
Actuadores (Manos, Voz)



### Robot:


Sensores (Cámaras, Infrarrojos)  
→ Actuadores (Motores)



### Software:

Sensores (Teclado, Red) →  
Actuadores (Pantalla, Archivos)

Figura2.1: El Ciclo de Interacción



# Agentes

## *Agentes simbólicos*

Cada tipo de agente se diferencia principalmente por cómo representan el conocimiento y cómo toman decisiones.

Se basan en la representación simbólica del conocimiento y el uso de reglas lógicas para razonar. Buscan emular el razonamiento humano a través de operaciones formales entre símbolos.

Ventajas:

- Transparencia en la toma de decisiones (explicable)
- Buen desempeño en dominios cerrados y estructurados.

Desventajas:

- Poca flexibilidad ante incertidumbre o entornos dinámicos.
- Escalabilidad limitada en problemas del mundo real.
- Difícil captura de conocimientos implícitos o ambiguos.

**SI** temperatura > 38°C  
**ENTONCES** paciente = “fiebre”

**SI** paciente = “fiebre”  
**Y** tos = verdadero  
**ENTONCES** diagnóstico = “gripe”

# Agentes

## *Agentes reactivos*

No construyen un modelo interno complejo del mundo. Responde de manera inmediata a estímulos de su entorno mediante reglas de condición-acción, sin usar memoria ni planificación, lo que lo hace rápido pero limitado en tareas complejas.

- Aspiradoras robot simples
- Sistemas de control industrial
- Agentes simples de videojuegos

**Un robot detecta un obstáculo.**

**SI** obstáculo\_delante

**ENTONCES** girar\_izquierda

# Agentes

## *Agentes basados en aprendizaje por reforzamiento (Reinforcement Learning)*

Se basa en una idea que todos conocemos: aprender de la interacción. Un agente explora un entorno, realiza acciones y recibe recompensas o castigos. En otras palabras, el sistema aprende a tomar decisiones mediante prueba y error en interacción con su entorno, recibiendo recompensas o castigos y ajustando su comportamiento para maximizar la recompensa acumulada a lo largo del tiempo.

Toman decisiones secuenciales y pueden mejorar su rendimiento con la experiencia.  
*AlphaGo.*

- Imaginemos a un niño frente a un videojuego por primera vez.
- Presiona un botón (acción) y recoge una moneda (recompensa +1). *Aprende* que las monedas son buenas.
- Luego, toca un enemigo (acción) y pierde una vida (recompensa +1). Aprende que los enemigos son malos.
- Sin supervisión, el niño mejora. Los agentes hacen lo mismo.

# Agentes

## *Agentes con transferencia de aprendizaje*

Aquel agente que reutiliza el conocimiento adquirido en una tarea o entorno para adaptarse y aprender más rápido en nuevas tareas, reduciendo el costo de entrenamiento y mejorado su capacidad de generalización.

- Generalizan más allá de la tarea de origen.
- Pueden reutilizar representaciones aprendidas a partir de otros modelos.
- Se relacionan con el meta-aprendizaje (“aprender a aprender” nuevas tareas de manera eficiente).

# Agentes

## *Agentes basados en LLMs (Large Language Models)*

Son la evolución más reciente. Utilizan a los grandes modelos de lenguaje como núcleo (“cerebro”) del agente, combinando capacidades de comprensión y generación de lenguaje con percepción multimodal y acciones en el entorno.

Su conocimiento está distribuido en miles de millones de parámetros entrenados mediante aprendizaje profundo.

- Habilidad para interactuar en lenguaje natural.
- “Razonamiento” y planificación, incluso escenarios complejos (CoT, descomposición de tareas).
- Memoria y transferencia entre dominios.
- Posibilidad de usar herramientas externas (APIs, buscadores, bases de datos) y encarnarse en entornos físicos (embodiment).



# Agentes

| Propiedad            | Definición                                                                                                                                                                                                | Ejemplo                                                                                                                        |
|----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Autonomía            | Capacidad de actuar y tomar decisiones sin intervención humana directa, administrando sus estados, objetivos y acciones. <i>Generar respuestas sin instrucciones paso a paso, establecen metas.</i>       | Un agente recibe el objetivo de elaborar un informe, busca información, organiza las secciones, redacta y revisa el documento. |
| Reactividad          | Capacidad de responder de manera inmediata y adecuada a cambios o estímulos del entorno. <i>Procesan información en tiempo real, adaptables a diferentes dominios.</i>                                    | Un asistente modifica una recomendación cuando el usuario proporciona nuevos datos o corrige una condición inicial.            |
| Proactividad         | Capacidad de actuar con iniciativa, anticiparse a necesidades y realizar acciones orientadas al cumplimiento de metas. <i>Descomponen objetivos complejos, planifican subtareas, generar estrategias.</i> | Un agente detecta que faltan datos para completar una tarea y propone obtenerlos antes de continuar.                           |
| Habilidades sociales | Capacidad de comunicarse, colaborar y coordinarse con personas y otros agentes. <i>Comprenden lenguaje natural, mantienen el contexto, adoptan roles.</i>                                                 | Varios agentes asumen los roles de investigador, revisor y editor para mejorar un artículo científico/reporte.                 |

# Un camino hacía la IA general (IAG)

Una IA actual puede ser buena generando textos, otra distinta puede estar especializada en analizar imágenes médicas. Una IAG podría realizar ambas tareas (incluyendo otras), aprender una nueva disciplina y aplicar conocimientos previos para resolver problemas nuevos.

Para lograr avances reales para entender el lenguaje, debemos lograr que los modelos enfrenten el mundo a diferentes niveles, a los cuales se les llama *World Scopes*:

- **Corpus:** Recopilar, preprocesar y anotar documentos para estudiar cómo representarlos.
- **Internet:** La utilización de datos no estructurados, no etiquetados, multi-dominio al nivel de recopilar todo lo que la humanidad ha escrito, mejora nuestras representaciones.
- **Percepción:** Se incorporan nuevas modalidades de datos.
- **Personificación:** Se incluye el actuar sobre el mundo, seguir instrucciones y entender las implicancias físicas del lenguaje.
- **Social:** Se añaden interacciones para entender intenciones, emociones y los efectos del lenguaje sobre otros.

# Agentes autónomos basados en LLMs

Al elevar los LLMs al estatus de agentes autónomos y equiparlos con herramientas para expandir su espacio de percepción y acción, podríamos potencialmente llevar al tercer y cuarto nivel de los World Scopes.


Además, estos agentes podrían ejecutar tareas más complejas a través de la cooperación y competencia, emergiendo así fenómenos sociales que podrían ayudarnos a llegar al quinto nivel.

Fuente: The Rise and Potential of Large Language Model Based Agents: A Survey

# Sociedad con interacción agente-humano



# Arquitectura de un Agente basado en LLMs



# Arquitectura de un Agente basado en LLMs

## *Cerebro*

El cerebro humano es una estructura sofisticada capaz de procesar gran cantidad de información, generar pensamientos, controlar comportamientos, etc. Al igual que los humanos, el cerebro funciona como núcleo central de un agente de IA.

Después de recibir información desde el módulo de percepción, el agente primero recupera conocimiento desde su memoria, lo cual le ayuda a tomar decisiones más informadas. Además, puede memorizar ("aprender") cosas nuevas. Presenta algunas facetas:

- Interacción en Lenguaje Natural
- Conocimiento
- Memoria
- Razonamiento y Planeación
- Transferibilidad y Generalización

# Cerebro

## *Conocimiento*

Corresponde a la información general y especializada que el modelo incorpora durante su entrenamiento y que utiliza para comprender, razonar y tomar decisiones, complementándose con fuentes externas como bases de datos o buscadores para mantenerse actualizado.

- Integran el conocimiento general adquirido durante el preentrenamiento.
- Incorporan conocimiento especializado de dominio.
- Pueden actualizarse y ampliarse mediante fuentes externas.

# Cerebro

## *Memoria*

Es la capacidad del agente para almacenar, recuperar y utilizar experiencias pasadas (observaciones, acciones e interacciones con el usuario) con el fin de mejorar su comportamiento futuro.

- Memoria a corto plazo: contexto de la conversación (ventana de tokens).
- Memoria a largo plazo: almacenamiento externo mediante resúmenes, vectores o bases de datos.
- Permite adaptar respuestas y dar continuidad a tareas complejas o de múltiples pasos.



# Cerebro

## *Razonamiento y Planeación*

Capacidad del agente para analizar información, inferir conclusiones y organizar acciones en secuencias que le permitan alcanzar metas específicas.

- Razonamiento: uso de técnicas como Chain of Thought, auto-reflexión y verificación de consistencia.
- Planificación: descomposición de problemas complejos en subtarefas, formulación de planes jerárquicos y ajuste dinámico según retroalimentación.

# Cerebro

## *Transferibilidad y Generalización*

Capacidad del agente para aplicar conocimiento y habilidades adquiridos en una tarea o dominio a nuevas situaciones, incluso cuando no han sido vistas durante el entrenamiento.

- In-context learning: aprenden patrones directamente del contexto de la interacción sin modificar parámetros.
- Adaptación a múltiples dominios (lenguaje, programación, medicina, derecho, etc.)

# Arquitectura de un Agente basado en LLMs

## *Percepción*

Tanto los humanos como los animales tenemos órganos sensoriales que nos permiten captar información de nuestro entorno. Estas entradas perceptuales son procesadas y enviadas al cerebro para tomar percibir o interactuar con el mundo.

Para los agentes, es crucial que los LLMs reciban información desde varias fuentes y modalidades para entender de mejor manera su ambiente, realizar decisiones informadas y destacar en muchas tareas; luego llevada al cerebro. Algunas entradas pueden ser:

- Textual
- Visual
- Auditiva
- (en un futuro) Táctil, olfativa, temperatura, humedad, mapas 3D, etc.

# Arquitectura de un Agente basado en LLMs


## *Acción*

Después de que los humanos perciban su entorno, nuestro cerebro integra, analiza y razona sobre la información percibida para tomar decisiones. Seguidamente, empleamos nuestros sistemas nerviosos para controlar nuestros cuerpos y crear acciones en respuesta a nuestro entorno. Algunas acciones que el agente puede realizar son:

- Texto
- Utilización de herramientas
- Personificar
  - Observar
  - Manipular
  - Navegar

# Habilidades de un agente único

Se trata de un solo agente. Son los agentes más valorados y más prevalentes dado que son capaces de mejorar la eficiencia en alguna tarea y disminuir la carga de trabajo de un usuario.



# Habilidades de un agente único

## *Orientados a tareas*

Agentes diseñados para cumplir objetivos prácticos y bien delimitados, comprendiendo instrucciones en lenguaje natural y descomponiéndolas en subtareas ejecutables hasta alcanzar la meta.

- Capacidad de interpretar órdenes de usuarios.
- Realizan planificación secuencial (dividir meta / acciones).
- Operan en entornos cotidianos: web, hogar, oficina, etc.

# Habilidades de un agente único

## *Orientados a la innovación*

Agentes que no solo ejecutan tareas directas, sino que exploran, descubren y generan nuevo conocimiento o soluciones creativas, apoyando la innovación científica y tecnológica.

- Capacidad de formular hipótesis y experimentos virtuales.
- Uso de herramientas externas (APIs, buscadores, entornos de simulación, laboratorios virtuales).
- Manejo de información especializada (códigos, papers, datos científicos).

# Habilidades de un agente único

## *Orientados al ciclo de vida*

Agentes diseñados para sobrevivir y adaptarse continuamente en entornos abiertos, aprendiendo nuevas habilidades y acumulando experiencias para mantener su utilidad a largo plazo.

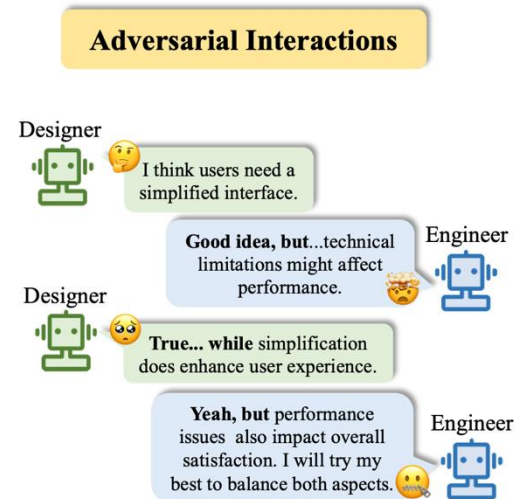

- Aprendizaje continuo: incorporan nuevas estrategias sin reiniciar entrenamiento.
- Expanden su “biblioteca de habilidades” con experiencias previas (lifelong learning).
- Capacidad de explorar y automejorarse en entornos dinámicos.



# El potencial de múltiples agentes

La falta de interacciones sociales entre agentes genera que el paradigma de un solo agente restrinja el potencial que tienen los agentes.

La división del trabajo puede llevar a que los agentes alcancen su rendimiento óptimo al enfocar el trabajo de cada uno en **resolver una tarea u objetivo** en conjunto.



# El potencial de múltiples agentes

## *Interacción cooperativa*

Ocurre cuando varios agentes colaborar para alcanzar un objetivo común, compartiendo información, habilidades o recursos de manera coordinada. Cada agente asume un rol especializado; si un agente “no puede”, los demás ayudan; organización.

## *Interacción adversaria*

Se da cuando varios agentes compiten entre sí o se desafían mutuamente, generando dinámicas de confrontación que mejoran su rendimiento.

## *Interacción persona-agente*

Colaboración entre humanos y agentes basada en lenguaje natural u otras modalidades, donde el humano guía, supervisa o coopera con el agente para completar tareas de manera más eficiente y segura.

# El potencial de múltiples agentes

Es un patrón de diseño diseñado para agentes de IA en el que el modelo combina razonamiento explícito con instrucciones o herramientas para resolver una tarea.

En lugar de generar una respuesta directamente, el agente sigue un ciclo iterativo:

Pensar (Reasoning) → Actuar (Action) →  
Observar (Observation) → Repetir ...

Cada observación obtenida del entorno alimenta el siguiente razonamiento hasta llegar a la respuesta final.

(1d) ReAct (Reason + Act)

**Thought 1:** I need to search Apple Remote and find the program it was originally designed to interact with.

**Act 1:** `Search[Apple Remote]`

**Obs 1:** The Apple Remote is a remote control introduced in October 2005 by Apple ... originally designed to control the Front Row media center program ...

**Thought 2:** Apple Remote was originally designed to control the Front Row media center program. I need to search Front Row next and find what other device can control it.

**Act 2:** `Search[Front Row]`

**Obs 2:** Could not find [Front Row]. Similar: ['Front Row Seat to Earth', 'Front Row Motorsports', 'Front Row (software)', ...]

**Thought 3:** Front Row is not found. I need to search Front Row (software) .

**Act 3:** `Search[Front Row (software)]`

**Obs 3:** Front Row is a discontinued media center software ...

**Thought 4:** Front Row (software) is controlled by an Apple Remote or the keyboard function keys. So the answer is keyboard function keys.

**Act 4:** `Finish[keyboard function keys]`

