

CURSO RAG · CLASE 4

Graph RAG

RAG con grafos y knowledge graphs

RAG clásico: flujo y límites



Fortalezas

Fácil de prototipar, costo moderado, QA puntual funciona bien.



Límites

Razonamiento multihop débil, relaciones implícitas frágiles, context stuffing, difícil asegurar cobertura global.

Consideremos esta pregunta:

“¿Qué nombre tiene el hijo del inventor de la teoría de la relatividad?”

Flujo del RAG clásico



Un retriever vectorial busca un chunk parecido a la pregunta completa — pero esta pregunta requiere dos saltos de razonamiento encadenados.

Knowledge Graphs como memoria flexible en RAG

- Un knowledge graph (KG) representa datos estructurados y no estructurados como elementos conectados.
- A diferencia de las BD tradicionales, no exige un esquema rígido; el modelo es flexible y evolutivo.
- Facilita almacenamiento, gestión, consulta y procesamiento de la riqueza de la información del mundo real.
- En un sistema RAG, el KG actúa como memoria flexible que complementa las habilidades lingüísticas del LLM (resumir, traducir, extraer).



Knowledge Graphs

- Organizan por relaciones
- Nodos + aristas tipadas
- Sin esquema rígido



Vector Database

- Organiza por similitud
- Embeddings numéricos
- Búsqueda por distancia

¿Qué es Graph RAG?

Idea clave: extraer un grafo de conocimiento (entidades, relaciones, atributos) desde el corpus y usarlo para recuperar evidencias y razonar sobre conexiones. GraphRAG es un enfoque estructurado y jerárquico de la generación aumentada por recuperación.

PIEZAS CLAVE

- 1 Extracción de entidades y relaciones
- 2 Construcción de grafo léxico / de entidades
- 3 Detección jerárquica de comunidades
- 4 Resúmenes por comunidad y nivel
- 5 Mecanismos de consulta local y global

Componentes del grafo



Nodos

- Entidades: personas, organizaciones, conceptos, lugares
- Documentos / chunks (léxico)



Aristas

- Relaciones con tipo y peso
- Co-mención, relación extraída, similitud, citación



Atributos

- Fuente, spans, confianza
- Embeddings asociados



Comunidades

- Agrupaciones multi-nivel
- Capturan temas y cohesión

Arquitectura de consulta GraphRAG



Arquitectura tipo (Microsoft GraphRAG)

El proceso de indexación incluye cuatro pasos clave:

1

Segmentación de unidades de texto

Todo el corpus de entrada se divide en múltiples unidades de texto (fragmentos de texto).

2

Extracción de entidades y relaciones

Identificar y extraer entidades (personas, lugares, organizaciones), relaciones y afirmaciones clave en cada unidad textual.

3

Agrupación jerárquica

Un algoritmo de detección de comunidades descubre eficazmente las estructuras comunitarias dentro del grafo.


4

Generación de resúmenes de la comunidad


Resúmenes por comunidad y sus miembros: entidades principales, relaciones y afirmaciones clave — contexto útil para consultas.

De documentos a respuesta global

INDEXING TIME



QUERY TIME



Fuente: From Local to Global: A GraphRAG Approach to Query-Focused Summarization — Microsoft Research, arxiv.org/pdf/2404.16130

Recuperación local vs global vs híbrida

OPCIONAL · NO IMPLEMENTADO EN EL NOTEBOOK



Local (vecindad)

Expansión k-hop con filtros por tipo de arista; útil para preguntas puntuales ("¿quién colabora con X?").



Global (comunidades)

Detección de comunidades (Louvain/Leiden), topic labeling y resúmenes jerárquicos; útil para "panoramas".



Híbrida

Self-query retriever → KG + Vector; fusión por reciprocal rank, score normalizado o RRF.

Aspecto	Local	Global
Pregunta	Puntual, factual	Panorámica
Unidades	Entidades, aristas	Comunidades
Riesgos	Missing edges	Sobre-resumir

Implementación con Neo4j



BD de grafos nativa + Cypher

Nodos/relaciones/propiedades y consultas explicables multi-salto.



Embeddings + búsqueda vectorial

Índices y similitud en Cypher; combina embeddings con señales de grafo.



Cloud: Neo4j AuraDB gratis

Para prototipos — hasta 200k nodos / 400k relaciones.

ALTERNATIVAS

Microsoft GraphRAG

Azure AI Search + Azure OpenAI

Amazon Bedrock Knowledge Bases

Google Vertex AI Search

Ejemplo end-to-end: grafo de investigadores

NUEVO · EL MISMO GRAFO DEL NOTEBOOK DE LA CLASE 4



PREGUNTA (lenguaje natural)

“¿Cuántos artículos ha publicado Emily Chen?”

CYPHER GENERADO

```
MATCH (r:Researcher
      {name:"Emily Chen"})
      -[:PUBLISHED]->(a:Article)
RETURN COUNT(a)
```

RESPUESTA

7 artículos.

Un RAG vectorial no puede contar —
tiene que recorrer el grafo completo.

Variantes de GraphRAG

NUEVO · NO TODOS LOS GRAPH RAG SON IGUALES

Variante	Cómo indexa	Trade-off
Microsoft GraphRAG	Comunidades jerárquicas + resúmenes multi-nivel generados por LLM	Muy completo; indexación costosa en tiempo y tokens
LightRAG	Indexación dual-level (bajo/alto nivel), más liviana	Más rápido y barato de indexar; menos exhaustivo
Neo4j + LLM Graph Builder	El LLM extrae entidades/relaciones directo a Neo4j	Integrado a la BD de grafos; requiere afinar el prompt de extracción
Enfoque de este curso	Grafo ya estructurado (CSV) + Cypher QA chain	Simple y barato; no extrae el grafo desde texto libre

GraphRAG vs RAG vectorial: ¿cuándo usar cada uno?

NUEVO • COSTO, LATENCIA Y TIPO DE PREGUNTA

Dimensión	RAG vectorial	GraphRAG
Costo de indexación	Bajo — chunking + embeddings	Alto — extracción de entidades/relaciones + comunidades
Latencia de consulta	Baja — un solo lookup vectorial	Media/alta — travesía de grafo o generación de Cypher
Resuelve bien	Búsqueda temática, QA puntual	Conteos, agregaciones, preguntas multi-hop
Mantenimiento	Reindexar al agregar documentos	Reindexar grafo + revisar esquema de entidades

Regla práctica: si la pregunta requiere contar, agregar o conectar entidades entre sí, GraphRAG gana. Si es búsqueda temática simple, RAG vectorial basta — y es más barato.

RESUMEN

Lo que vimos en GraphRAG

1

KG como memoria

Nodos, aristas, atributos y comunidades sin esquema rígido

2

Arquitectura GraphRAG

Segmentación → extracción → comunidades → resúmenes

3

Vector + grafo combinados

retrieval_query: travesía de grafo dentro de la búsqueda vectorial

4

Neo4j + Cypher

Vector index + GraphCypherQChain sobre la misma base

Con esto cerramos el arco de las 4 clases: RAG Simple → RAG Avanzado → Evaluación de RAG → GraphRAG.